

Warum Sie nicht (nur) auf Basis von Daten entscheiden sollten





Sebastian Sauer

<https://raw.githubusercontent.com/sebastiansauer/talks/main/2024/causal-bizz/causal-bizz.pdf>

<https://raw.githubusercontent.com/sebastiansauer/talks/main/2024/causal-bizz/causal-bizz-moderator-notes.pdf>

Gliederung

- > Fallstudie *Bot im Webshop* 
- > Fallstudie *Blutdruck-Pille* 
- > Fazit

Fallstudie

Bot im Webshop

3

Stellen Sie sich vor, Sie arbeiten bei einer Firma mit einem Webshop, vielleicht eine Firma, die Elektronikartikel an Privatkunden verkauft, so wie MediaMarkt.

Jetzt haben Sie neu einen Bot eingerichtet (ChatGPT und so...), der die Kunden beim Kauf berät. Der Bot ist noch neu, Sie wissen also noch nicht gut, ob der Bot „was bringt“, also die Verkäufe ankurbelt, das wäre jedenfalls Ihr Wunsch.


„Der Bot ist Schrott.“

Wolfi



Bot → Kaufabschluss

Wolfis Kausalmodell



Das Beispiel basiert auf Pearl, J., Glymour, M., & Jewell, N. P. (2016). Causal inference in statistics: A primer. Wiley.

Behindert der Bot den Kaufabschluss?

Gruppe	Bot 🤖	kein Bot 🚫🤖
Männer 👨	81/87 Kaufabschluss (93%)	234/270 Kaufabschluss (87%)
Frauen 👩	192/263 Kaufabschluss (73%)	55/80 Kaufabschluss (69%)
GESAMT	273/350 Kaufabschluss (78%)	289/350 Kaufabschluss (83%)

6


350 Personen haben sich für den Bot entschieden, 350 dagegen.

Männer sollten den Bot bekommen, Frauen auch — das erhöht den Kaufabschluss. Aber wenn wir das Geschlecht nicht kennen, sollte KEIN Bot angeboten werden. Das kann doch nicht sein!

Die Daten liefern KEINE Lösung für dieses (scheinbare) Paradoxon. Wir müssen die Kausalzusammenhänge wissen, um zu wissen, wir den Bot anbieten sollten oder nicht.

„Bei Frauen
und Männern
ist der Bot gut.
Aber nicht
insgesamt?!“

Ron




Gruppe	Bot 🤖	kein Bot 🚫🤖
Männer 🧔	81/87 Kaufabschluss (93%)	234/270 Kaufabschluss (87%)
Frauen 🧑	192/263 Kaufabschluss (73%)	55/80 Kaufabschluss (69%)
GESAMT	273/350 Kaufabschluss (78%)	289/350 Kaufabschluss (83%)

„Männliches
Geschlecht ist die
Ursache von
geringerer Bot-
Nutzung und
höherem
Kaufabschluss.“

„Der Bot hat
keinen Effekt
auf den
Kauf-
abschluss.“

Angie




Angenommen, wir haben zusätzliches Wissen: Männer sind den Produkten zugeneigter als Frauen, vollziehen also häufiger einen Kaufabschluss. Außerdem nutzen Männer den Bot nicht so gern.

Wenn wir also zufällig eine Person betrachten, die den Bot nutzt, wird es vermutlich eine Frau sein. Und Frauen kommen nicht so häufig zum Kaufabschluss. Daher können wir so nicht klar sehen, ob der Bot einen Effekt auf den Kaufabschluss hat.

Stattdessen müssen wir Menschen des gleichen Geschlechts vergleichen. Innerhalb eines Geschlechts kann der Unterschied im Kaufabschluss nicht auf Unterschiede im Geschlecht liegen. Sondern muss am Bot liegen. Der Schluss gilt natürlich nur, wenn unser Kausalmodell stimmt.

„Männliches
Geschlecht ist die
Ursache von
geringerer Bot-
Nutzung und
höherem
Kaufabschluss.“

Angie




Gruppe	Bot 🤖	kein Bot 🚫🤖
Männer 👨	81/87 Kaufabschluss (93%)	234/270 Kaufabschluss (87%)
Frauen 👩	192/263 Kaufabschluss (73%)	55/80 Kaufabschluss (69%)
GESAMT	273/350 Kaufabschluss (78%)	289/350 Kaufabschluss (83%)

Ron: Angie, du bist schlau! Bin ich froh, dass wir dich haben.

Angie: Ja, ich weiß. Ich bin auch froh.


„Was ist eine
Ursache?“

Ron




„Wenn du X
änderst, ändert
sich auch Y.“

Angie




Ursache: Wenn man **X** ändert, ändert sich auch **Y**

X ist Ursache von Y

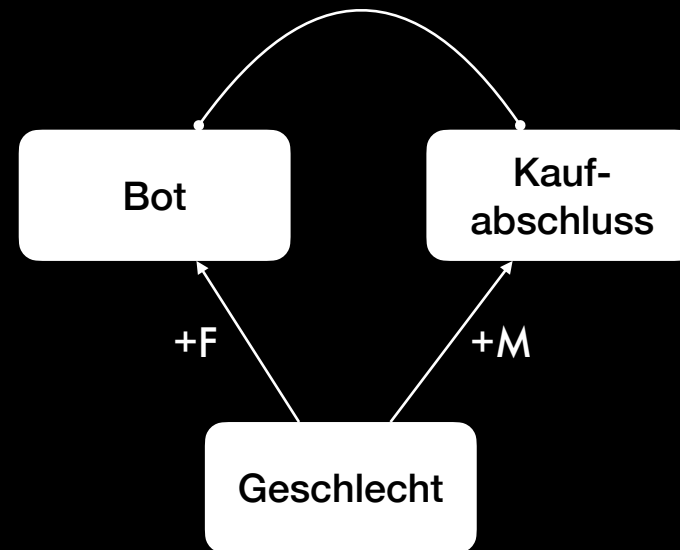


X ist *NICHT* Ursache von Y



Bot ← Geschlecht → Kaufabschluss

Angies Kausalmodell



12

Kausalstrukturen dieser Art nennt man „Konfundierung“ oder auch „Gabel“ („fork“).


Der Effekt von Geschlecht bewirkt: Entweder gibt es Kunden (Frauen), die den Bot nutzen, aber nix kaufen. Oder es gibt Kunden (Männer), die den Bot ablehnen, aber viel kaufen.

Bot-Nutzerinnen kaufen nicht; Bot-Nutzer kaufen. Ergo: Wenn Bot, dann nix kaufen, Wenn kein Bot, dann kaufen. Dieser Zusammenhang zwischen Bot und Kaufabschluss ist aber nur ein Scheinzusammenhang, vermittelt über Geschlecht. Die geschweifte Klammer stellt den Schein-Zusammenhang dar.

Ein Schein-Zusammenhang ist ein Zusammenhang, der nicht durch eine Kausation begründet ist.


„Woher weiß ich,
ob dein
Kausalmodell
stimmt?“

Ron



„Wenn du Frauen
und Männer
getrennt
betrachtest, muss
die Kaufabsicht
konstant bleiben.“


Angie




Man kann eine Kausation ausschließen, indem man X konstant und hält und schaut, ob Y auch konstant bleibt (oder zumindest sich nicht systematisch mit X verändert). Umgekehrt kann man zeigen, dass eine Kausation vorliegt, wenn man X variiert und dann Y auch (systematisch) variiert — natürlich muss man dann die Wirkung anderer möglicher Einflüsse auf Y ausschließen können.

Ursache: Wenn man **X** nicht ändert ... ändert sich auch **Y** NICHT

X ändern →
Y ändert sich nicht

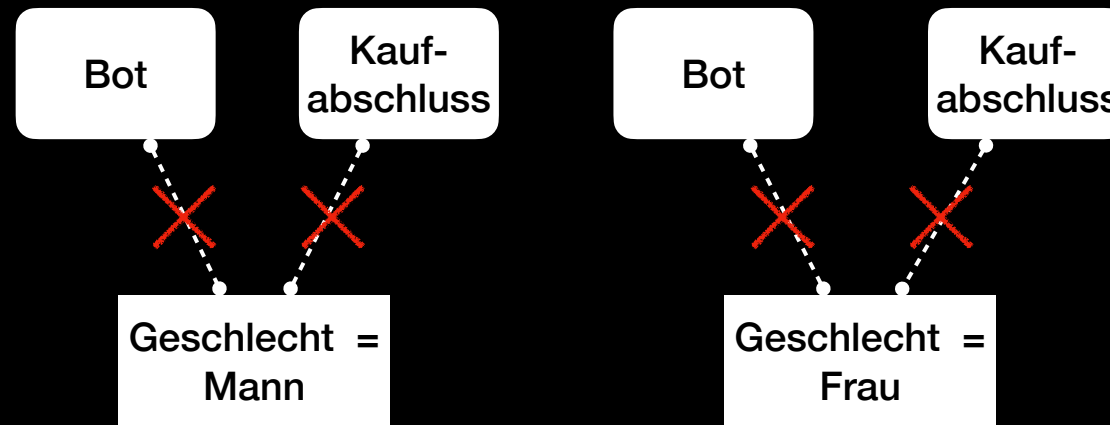


X nicht ändern →
Y ändert sich nicht



Geschlechter getrennt betrachten

so wird der Kausaleffekt von Geschlecht ausgeschaltet




15

Die Geschlechter, also Frauen und Männer, getrennt zu betrachten, bedeutet, die Variable „Geschlecht“ konstant zu halten. Innerhalb der Geschlechtergruppen dürfte es keinen Zusammenhang mehr geben zwischen Bot und Kaufabschluss (wenn das Modell richtig ist).

„Die Teildaten
zeigen den
Kausaleffekt.“

Angie




Gruppe	Bot 🤖	kein Bot 🚫🤖
Männer 🧑	81/87 Kaufabschluss (93%)	234/270 Kaufabschluss (87%)
Frauen 🧑	192/263 Kaufabschluss (73%)	55/80 Kaufabschluss (69%)
GESAMT	273/350 Kaufabschluss (78%)	289/350 Kaufabschluss (83%)

Angies Kausalmodell nimmt an, dass der Bot keinen Kausaleffekt auf die Kaufabsicht hat. Die Daten zeigen uns aber, dass Angie sich irrt. Der Bot hat einen Kausaleffekt auf die Kaufabsicht. Angies Kausalmodell nennt man eine Konfundierung.

„Oh. Der Bot erhöht den Kaufabschluss.“

Angie




Gruppe	Bot 🤖	kein Bot 🚫🤖
Männer 🧑	81/87 Kaufabschluss (93%)	234/270 Kaufabschluss (87%)
Frauen 🧑	192/263 Kaufabschluss (73%)	55/80 Kaufabschluss (69%)
GESAMT	273/350 Kaufabschluss (78%)	289/350 Kaufabschluss (83%)

Schlüsse über Kausaleffekte sind dabei nur gültig, wenn das zugrunde gelegte Modell stimmt.


„Also den
Bot
nutzen?“

„Ja.“

Ron



Angie

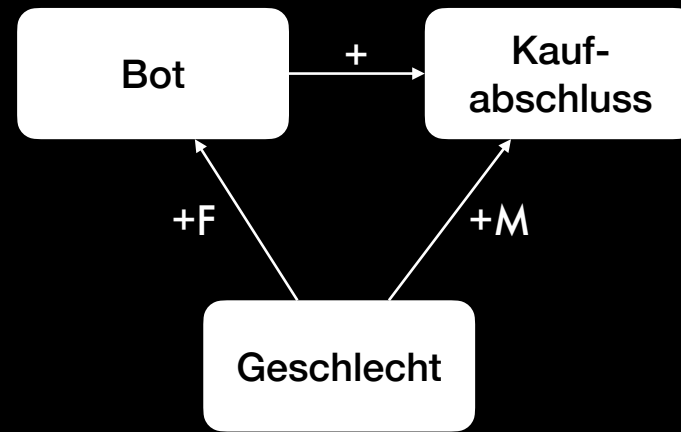






Angie: Krieg ich jetzt eine Gehaltserhöhung?

Ron: Äh, nein.

Die Teil-Daten zeigen den Kausaleffekt

Die **GESAMT**-Daten sind irreführend



Gruppe	Bot 	kein Bot 
Männer 	81/87 Kaufabschluss (93%)	234/270 Kaufabschluss (87%)
Frauen 	192/263 Kaufabschluss (73%)	55/80 Kaufabschluss (69%)
GESAMT	273/350 Kaufabschluss (78%)	289/350 Kaufabschluss (83%)

Fallstudie *Blutdruck-Pille*

20

Das Beispiel basiert auf Pearl, J., Glymour, M., & Jewell, N. P. (2016). Causal inference in statistics: A primer. Wiley.

„Immer rein damit. Die Pille ist
super.“

Wolfi



21

Stimmen Sie Wolfi zu?

Pille einnehmen?

Gruppe	keine Pille 🚫💊	Pille 💊
niedriger Blutdruck	81/87 Heilung (93%)	234/270 Heilung (87%)
hoher Blutdruck	192/263 Heilung (73%)	55/80 Heilung (69%)
GESAMT	273/350 Heilung (78%)	289/350 Heilung (83%)

22

350 Personen haben sich für das Medikament entschieden, 350 dagegen (nehmen keines).


Hier ist die Heilungsrate (-chance) berichtet, außerdem der Blutdruck (hoch/niedrig) zum Ende der Studie.

Die Daten liefern KEINE Lösung für dieses (scheinbare) Paradoxon. Wir müssen die Kausalzusammenhänge wissen, um zu wissen, welche Entscheidung bzw. welche Handlung zum besseren Ergebnis führt.

Übrigens sind es die gleichen Zahlen wie in der anderen Fallstudie.


Pille → Heilung

Wolfis Kausalmodell



„Die Pille verringert den Blutdruck, was zur Heilung führt. Aber sie hat auch einen toxischen Effekt.“

Angie



24


Angenommen, wir haben zusätzliches Wissen: Das Medikament verringert den Bluthochdruck. Geringerer Bluthochdruck erhöht wiederum die Heilungschancen. Kurz gesagt: Das Medikament wirkt durch Verringerung des Blutdrucks.

Leider hat das neue Medikament zusätzlich einen toxischen Effekt, was die Heilungschancen verringert.

Angie kennt die Kausalwirkung des Medikaments und netterweise lässt sie uns an ihrem Wissen teilhaben.

Pille → Blutdruck/Tox → Heilung

Angies Kausalmodell




25

Solche Kausalmodelle nennt man Mediatormodelle: Die Wirkung der Pille wird über Blutdruck bzw. Tox-Effekt vermittelt („meditiert“) auf die Heilung.

„Die Pille wirkt durch Senkung des Blutdrucks. Es macht keinen Sinn, die Teil-Daten zu betrachten.“

Gruppe	keine Pille 🚫💊	Pille 💊
niedriger Blutdruck	81/87 Heilung (93%)	234/270 Heilung (87%)
hoher Blutdruck	192/263 Heilung (73%)	55/80 Heilung (69%)
GESAMT	273/350 Heilung (78%)	289/350 Heilung (83%)

Angie




Da die Pille durch Senkung des Blutdrucks wirkt, macht es keinen Sinn, den Blutdruck konstant zu halten, also die einzelnen Blutdruck-Gruppen zu betrachten. Innerhalb jeder Blutdruck-Gruppe ist der Blutdruck (per Definition) konstant (entweder „hoch“ oder „niedrig“). Der Effekt des Blutdrucks auf die Heilung ist also in den Teilgruppen nicht sichtbar. Die Wirkung der Pille ist also, dass die Patienten eher in die Gruppe „niedriger Blutdruck“ wechseln. Innerhalb der Blutdruck-Gruppen ist nur noch der toxische Effekt der Pille sichtbar.

„Die Gesamt-
Daten zeigen
den
Kausaleffekt.“

Gruppe	keine Pille 🚫💊	Pille 💊
niedriger Blutdruck	81/87 Heilung (93%)	234/270 Heilung (87%)
hoher Blutdruck	192/263 Heilung (73%)	55/80 Heilung (69%)
GESAMT	273/350 Heilung (78%)	289/350 Heilung (83%)

Angie




Da die Pille durch Senkung des Blutdrucks wirkt, macht es keinen Sinn, den Blutdruck konstant zu halten, also die einzelnen Blutdruck-Gruppen zu betrachten. Innerhalb jeder Blutdruck-Gruppe ist der Blutdruck (per Definition) konstant. Der Effekt des Blutdrucks auf die Heilung ist also so nicht sichtbar.


„Also die
Pille
nehmen?“

„Ja.“

Ron



Angie




Angie: Krieg ich jetzt eine Gehaltserhöhung?

Ron: Angie, willst du mich heiraten?

Angie: Äh, nein.

Die Gesamt-Daten zeigen den Kausaleffekt

Die Teil-Daten sind irreführend




Gruppe	keine Pille 🚫💊	Pille 💊
niedriger Blutdruck	81/87 Heilung (93%)	234/270 Heilung (87%)
hoher Blutdruck	192/263 Heilung (73%)	55/80 Heilung (69%)
GESAMT	273/350 Heilung (78%)	289/350 Heilung (83%)

Ein Kausalmodell der Art $X \rightarrow Y \rightarrow Z$ nennt man auch eine Mediation oder „Kette“.

Das Medikament hat zwei Wirkpfade: über „Blutdruck“ und über „Tox-Effekt“. Der erste Wirkpfad ist heilend, der zweite schädigend.

„Auf Basis der
Daten konnte
die Entscheidung
nicht getroffen
werden.“

Angie



„Hab ich
gleich
gewusst.“

Wolfi



Die Entscheidung, ob das Medikament eingenommen werden sollte, ist nicht anhand der Daten zu treffen, zumindest nicht alleine auf Basis der Daten. Die entscheidenden Informationen waren erstens, dass der Blutdruck im Nachhinein gemessen wurde. Zweitens dass das Medikament den Blutdruck senkt aber einen toxischen Effekt (auf die Heilung hat). Drittens, dass verringerter Blutdruck einen positiven Effekt auf die Heilung hat.





Die Lösung liegt nicht in den Daten — das ist insofern wahr, als die Daten in beiden Beispielen (Webshop vs. Blutdruck) identisch sind, die Entscheidungen aber gegensätzlich. Im ersten Beispiel galt es die Subgruppen zu betrachten für den Kausaleffekt, im zweiten Beispiel war es hingegen richtig, die Gesamtgruppen zu betrachten; die Subgruppen zeigten das falsche Ergebnis (nicht den wahren Kausaleffekt).

Fazit

Gleiche Daten, andere Entscheidung



Erst das Kausalmodell ermöglicht die Entscheidung

Bot im Webshop

Gruppe	Bot 	kein Bot 
Männer 	81/87 Kaufabschluss (93%)	234/270 Kaufabschluss (87%)
Frauen 	192/263 Kaufabschluss (73%)	55/80 Kaufabschluss (69%)
GESAMT	273/350 Kaufabschluss (78%)	289/350 Kaufabschluss (83%)

Teildaten 

Blutdruck-Pille

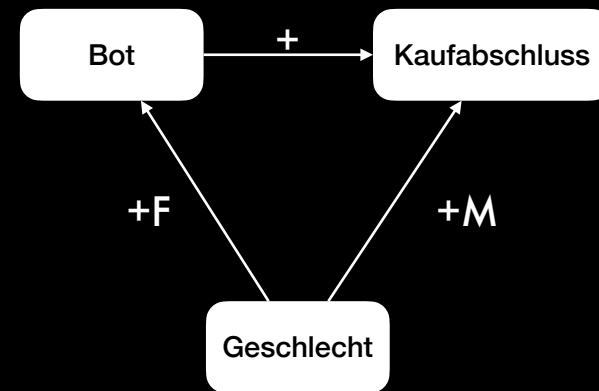
Gruppe	keine Pille 	Pille 
niedriger Blutdruck	81/87 Heilung (93%)	234/270 Heilung (87%)
hoher Blutdruck	192/263 Heilung (73%)	55/80 Heilung (69%)
GESAMT	273/350 Heilung (78%)	289/350 Heilung (83%)

Gesamtdaten 


Gleiche Daten, andere Entscheidung

Erst das Kausalmodell ermöglicht die Entscheidung

Bot im Webshop



Blutdruck-Pille



„Du musst wissen, was Ursache und Wirkung ist, wenn du gute Entscheidungen treffen willst.“

Wolfi




Für weise Tat
bedarf es Wissen
zum Kausalpfad,
offen und klar,
darf man nicht missen,
das ist wahr.

Wolfi



„Hör mit dem
Reimen auf,
Wolfi.“


Angie



Eigentlich wollte Wolfi rappen, aber vielleicht besser, dass er es nicht getan hat.


„Aber ist das nur
wirres
Professoren-
Zeugs?“

Ron



„Für das Zeugs
gab's 2021 den
Nobelpreis.“

Angie



<https://www.nobelprize.org/prizes/economic-sciences/2021/imbens/facts/>

Anhang

Literaturempfehlungen

Dablander, F. (2020). An Introduction to Causal Inference [Preprint]. PsyArXiv. <https://doi.org/10.31234/osf.io/b3fkw>

Dedering, U. (2010). Map of the USA [Map]. https://en.wikipedia.org/wiki/Saratoga_Springs_New_York#/media/

Elwert, F. (2013). Graphical causal models. In S. Morgan (Ed.), Handbook of causal analysis for social research (pp. 245–273). Springer. https://www.researchgate.net/publication/278717528_Graphical_Causal_Models

Hernán, M. A., Hsu, J., & Healy, B. (2019). A Second Chance to Get Causal Inference Right: A Classification of Data Science Tasks. Chance, 32(1), 42–49. <https://doi.org/10.1080/09332480.2019.1579578>

item2101. (2020). Avatar Icon Pack [Icon]. www.flaticon.com. <https://www.flaticon.com/packs/avatar-14?k=1587995971688>

Lübke, K. (2020, February). Introduction to Causal Inference. Dozententage der FOM, Essen.

Lübke, K., Gehrke, M., Horst, J., & Szepannek, G. (2020). Why We Should Teach Causal Inference: Examples in Linear Regression with Simulated Data. Journal of Statistics Education, 1–17. <https://doi.org/10.1080/10691898.2020.1752859>

Pearl, J. (2009). Causality. Cambridge university press.

Pearl, J., Glymour, M., & Jewell, N. P. (2016). Causal inference in statistics: A primer. Wiley.

Pearl, J., & Mackenzie, D. (2018). The book of why: The new science of cause and effect (First edition). Basic Books.

Rohrer, J. M. (2018). Thinking Clearly About Correlations and Causation: Graphical Causal Models for Observational Data. Advances in Methods and Practices in Psychological Science, 1(1), 27–42. <https://doi.org/10.1177/2515245917745629>

Shmueli, G. (2010). To Explain or to Predict? Statistical Science, 25(3), 289–310. <https://doi.org/10.1214/10-STS330>



 **Sebastian Sauer**

 sebastian.sauer@hs-ansbach.de




Folien:
<https://raw.githubusercontent.com/sebastiansauer/talks/main/2024/causal-bizz/causal-bizz.pdf>

Folien mit Kommentaren:
<https://raw.githubusercontent.com/sebastiansauer/talks/main/2024/causal-bizz/causal-bizz-moderator-notes.pdf>

39

<https://raw.githubusercontent.com/sebastiansauer/talks/main/2024/causal-bizz/causal-bizz.pdf>

<https://raw.githubusercontent.com/sebastiansauer/talks/main/2024/causal-bizz/causal-bizz-moderator-notes.pdf>



<https://xkcd.com/552/>

Bildnachweis

Personen-Icons: itim2101. (2020). *Avatar Icon Pack* [Icon]. www.flaticon.com. <https://www.flaticon.com/packs/avatar-14?k=1587995971688>

Kontaktseite: Font Awesome, <https://fontawesome.com/>